


تخمین زاویه ورود با استفاده از شبکه های عصبی



دانشجو: احمد رضا شهسواری
استاد راهنما: دکتر علی الفت
دانشکده مهندسی برق و کامپیوتر، دانشگاه تهران




نتایج

برای آموزش ساختار از بهینه ساز Adam استفاده شده است و برای شاخه DOAE تابع هزینه MAE و برای شاخه SED تابع هزینه binary cross-entropy در نظر گرفته شده است. نرخ یادگیری در ابتدا ۰.۰۰۱ بوده و پس از سی epoch، در هر مرحله آن را ده درصد کاهش می دهیم. سائز batch برابر ۳۲ قرار داده شده است. همچنین لازم به ذکر است که برای محاسبه ویژگی ورودی، فرکانس نمونه برداری برابر ۲۴ کیلوهرتز، فرکانس قطع برابر ۸ کیلوهرتز، تعداد نقاط FFT برابر ۵۱۲ و hop size برابر ۴۸۰ سمپل در نظر گرفته شده و از پنجره Hann با طول ۵۱۲ سمپل استفاده شده است. نتایج نهایی بدست آمده پس از حدود چهل epoch به صورت زیر می باشند:

Methods	ER	F-score	DOA (azimuth + elevation) Error	FR
Baseline	0.350	0.800	30.8°	0.840
Proposed method	0.279	0.841	14.286°	0.774

با مقایسه نتایج بدست آمده با نتایج مربوط به روش baseline معرفی شده برای دیتاست استفاده شده، میتوان دید که علی رغم استفاده از ساختارهایی که به دلیل سرعت بیشتر، دقت را به میزان اندکی کاهش می دهند، اما همچنان شاهد بهبود عملکرد قابل توجه ای نسبت به روش ذکر شده هستیم. در ادامه یک تصویر نمونه از پیش بینی های انجام شده، قرار داده شده است:



جمع بندی

در کاربردهای عملی، یک رویداد صدا همواره در یک یا چند جهت انتقال می یابد، به همین علت در مسائل SELD سعی می شود که هر دو وظیفه تشخیص صدا و موقعیت یابی را بطور همزمان انجام دهیم. در این پژوهش برای حل این مسئله از یک ساختار دو مرحله ای استفاده شد تا کارایی مربوط به هر دو وظیفه حفظ شود، همچنین برای افزایش سرعت ساختار در عین حفظ کارایی از یک ویژگی ورودی جدید استفاده شد که نسبت به دیگر ویژگی ها عملکرد مناسب تری دارد. در همین راستا برای معماری سیستم و استخراج ویژگی ها نیز از ساختار MobileNet استفاده شد که تا به حال در پژوهش دیگری از آن برای حل مسئله SELD استفاده نشده است.

مراجع اصلی

1. T. N. T. Nguyen, K. N. Watcharasupat, N. K. Nguyen, D. L. Jones, and W.-S.-Gan, "SALSA: Spatial cue-augmented log spectrogram for polyphonic sound event localization and detection," *arXiv:2110.00275*, 2021.
2. Y. Cao, Q. Kong, T. Iqbal, F. An, W. Wang, and M. D. Plumbley, "Polyphonic sound event detection and localization using a two-stage strategy," in *Detection and Classification of Acoustic Scenes and Events 2019 Workshop (DCASE2019)*, pp. 30–34, 2019.
3. A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M.-Andreetto, and H. Adam, "Mobilenets: Efficient convolutional neural networks for mobile vision applications," *arXiv preprint arXiv:1704.04861*, 2017.

مقدمه

تشخیص و مکان یابی رویدادهای صوتی، مسئله شناسایی رخدادهای صوتی مختلف و تخمین زدن موقعیت های زمانی و مکانی آنها است. اخیرا برای حل چنین مسائلی، از روش های مختلف یادگیری عمیق استفاده می شود؛ در حالیکه تشخیص رویداد صوتی غالبا بر الگوهای زمان-فرکانسی برای ایجاد تمایز بین کلاس های مختلف صدا تکیه دارد، اما در تخمین زاویه ورود معمولا از اختلاف های اندازه و یا فاز بین میکروفون ها برای تخمین جهت منابع استفاده می شود، به همین دلیل حل بهینه و همزمان این دو مسئله ممکن است دشوار باشد و درصورتیکه فرآیند آموزش آنها مشترک باشد، کارایی کاهش خواهد یافت. در این پژوهش برای رفع این مشکل از یک ساختار دو مرحله ای استفاده می شود که در آن برای یادگیری، یک ویژگی ورودی جدید به کار گرفته می شود؛ همچنین برای معماری شبکه عصبی نیز از ساختاری متفاوت با معماری های مرسوم استفاده می شود که نیازمند زمان یادگیری کمتری است.

روش پیشنهادی

نمایش STFT بردار سیگنال مشاهده شده توسط M کانال آرایه میکروفونی به صورت زیر خواهد بود:

$$X(t, f) = \sum_{i=1}^L S_i(t, f) \mathbf{h}(f, \phi_i, \theta_i) + N(t, f) \in \mathbb{C}^M$$

برای ویژگی ورودی ساختار، دو ویژگی مختلف را در کنار هم قرار می دهیم؛ ویژگی اول طیف log-linear است که به صورت زیر بدست می آید:

$$LINSPEC(t, f) = \log(|X(t, f)|^2) \in \mathbb{R}^{M \times T \times F}$$

برای ویژگی دوم با توجه به رابطه بردار سیگنال مشاهده شده، میتوان نشان داد که بردار هدایت متناسب با بردار ویژه اصلی ماتریس همبستگی سیگنال می باشد و میتوان از آن به صورت $-\frac{c}{2\pi f} \arg[U_1^*(t, f) U_{2:M}(t, f)]$ برای تخمین فواصل ورود طی شده استفاده کرد، اما در این حالت به علت نیاز به محاسبه بردار ویژه های اصلی، بدست آوردن ویژگیها از نظر محاسباتی پرهزینه خواهد بود درحالیکه در این پژوهش با توجه به ساختارهای استفاده شده، هدف افزایش سرعت در عین حفظ کارایی است، از این رو برای ویژگی دوم از NIPD استفاده می کنیم که به صورت زیر بدست می آید:

$$A(t, f) = -\frac{c}{2\pi f} \arg[X_1^*(t, f) X_{2:M}(t, f)] \in \mathbb{R}^{M-1}$$


که در حالتی که یک منبع غالب $S(t, f)$ داشته باشیم، یعنی:

$$X(t, f) \approx \mathbf{h}(t, f, \phi, \theta) S(t, f) + N(t, f)$$

در صورتیکه از هرگونه اعوجاج فازی به دلیل نویز صرف نظر کنیم، خواهیم داشت:

$$A(t, f) \approx -\frac{c}{2\pi f} \arg[h_1^*(t, f) \mathbf{h}_{2:M}(t, f)] \approx [d_{12}(t), \dots, d_{1M}(t)]^T$$

درنهایت ساختار سیستم طراحی شده بصورت زیر خواهد بود:



که در آن از ساختار زیر برای لایه های MobileNet استفاده شده است:

